

Case: Prediktion av Kreditrisk

Författare: Sam Moeini | Datum: 29 januari 2026

Sammanfattning

En maskininlärningsmodell har skapats för att identifiera kunder med hög risk att missa nästa månadsbetalning. Genom att utvärdera historisk kunddata har en **Gradient Boosting-modell** utvecklats som identifierar riskkunder med en **AUC på 0.78**. Implementering av denna modell bedöms kunna generera en besparing på ca **4 704 850** miljoner SEK givet antagandena i denna rapport.

Dataprocess och Antaganden

För att säkerställa modellens robusthet har följande steg och antaganden gjorts under databearbetningen:

- **Hantering av saknade värden:** Saknade värden (NaN) i kolumnerna Gender (x2), Education (x3) samt Default next month har ersatts med typvärdet med antagandet att ta det vanligaste värdet ger bäst representation. I kolumnerna ålder (x5) och kreditgräns (x1) ersattes NaN värdena med medianen då extremvärden inte ska vikta snittet i alldeles för hög grad. I kolumnen Martial status (x4) ersattes NaN värden med värdet 3 för att det beskrivs som other och antogs därav lämpligt. De saknade värdena i x6-x11 ersattes med -1 med antagandet att saknad data innebar att kunden skötte sin betalning. Slutligen i kolumnerna x12-x24 fylldes värdena med 0 med antagandet att saknad räkning innebär ingen räkning.
- **Identifierade brister och hantering:** I flaggkolumnen Default next month hittades två värden utanför det diskreta intervallet [0,1] som var 5 och 3, dessa värden omvandlades till 1 med antagandet att dessa kunder fallera. I kolumn x3 (education) hittades inklusive NaN 347 rader med värden utanför det diskreta intervallet, där dessa värden var [5, nan, 6, 0]. Värdena ersattes med 4 (others). I kolumnen x4 (martial status) hittades inklusive NaN 55 rader med värdet 0 eller NaN. Dessa värden ersattes med 3 (others). För kolumn x6-x11 har det upptäcktes 24 431 datapunkter med -2 och 95 993 datapunkter med värde 0. Denna kolumn har diskreta värdena (-1- 9) och var ej definierade för värden utanför intervallet. Därav har antagandet gjorts att dessa kunden betalat i tid (-1). I kolumnerna x12-x24 letades negativa värden. Kolumnerna x12-x17 har omkring 590-689 negativa värden per feature men tolkades som god kreditattribut. I kolumn x24 (income in application) hittades 3 negativa rader som tolkades orimligt och ersattes med 0.
- **Modellval:** Tre algoritmer utvärderades: *Logistisk Regression*, *Random Forest* och *Gradient Boosting* då dessa modeller utgör industristandard för tabulära klassificeringsproblem. Strategin var att börja med en tolkbar linjär baslinje (LogReg) och sedan utvärdera om mer komplexa trädmodeller (RF/GB) kunde fånga icke-linjära mönster i betalningshistoriken. Att inkludera mer exotiska modeller som Neurala Nätverk bedömdes ge en försumbar prestandaökning i förhållande till den ökade komplexiteten och träningstiden för denna datamängd. Därtill problematiken med att dessa deeplearning modeller innefattar en viss blackbox aspekt som leder till compliance risk.

Resultat och Prestanda

En analys av variablernas påverkan (Feature Importance) visar att **betalningsstatus föregående månad (x6)** är den enskilt starkaste indikatorn på framtida risk, följt av betalningsstatus 2 månader innan (x7).

Mätvärde	Resultat	Tolkning
ROC-AUC	0.78	God förmåga att rangordna kunder efter risk.
Precision (Default)	0.67	När modellen larmar, har den rätt i 67% av fallen.
Recall (Default)	0.36	Modellen fångar upp 36% av alla faktiska defaults.

Kommentar: Fokus har lagts på att maximera Precision för att minimera kostnaden för onödiga åtgärder mot skötsamma kunder.

Ekonomisk Konsekvensanalys

För att översätta modellens prestanda till affärsvärde har en kostnadssimulering genomförts på testpopulationen. Följande parametrar har använts:

- **Kostnad vid default: [51 331.2] SEK.** Baserat på genomsnittlig utestående skuld (x12) i testdatat.
- **Kostnad för åtgärd: 50 SEK.** Estimerad kostnad för bearbetning.
- **Success rate: 20%.** Antagande att vi lyckas förhindra default hos 1 av 5 kontaktade riskkunder.

Estimerad Besparing

Genom att applicera modellen och agera på de identifierade riskkunderna estimeras följande utfall jämfört med att inte agera alls:

Potentiell besparing: 4 704 850 miljoner SEK
ROI: För varje investerad krona i bearbetning räddas 133.85 kr.

Diskussion

Mitt antagande att de 120 424 ((0:99 993) + (-2:24 431)) datapunkter som ansågs som anomalier i kolumnerna x6-x11 blev definerade som -1 (pay duly) kan vara en kritisk felkälla. Om jag hade haft mer tid och resurser hade man kunnat hitta en bättre strategi att felhantera dessa kolumner.